
Project Report

JSONLLM: Extração Escalável de Atributos de Produtos com Grandes Modelos de Linguagem (LLMs)

João Vítor Fernandes Dias *
Computer Science Postgraduate Program
2024711370
Federal University of Minas Gerais
Belo Horizonte, MG; 31270-901
joaovitorfd2000@gmail.com

Melissa Dias Mattos
Computer Science Postgraduate Program
2024675063
Federal University of Minas Gerais
Belo Horizonte, MG; 31270-901
melissadmattos366@gmail.com

Abstract

Muitos produtos de *e-commerce* possuem múltiplos atributos – como tamanho, cor e material – que são essenciais para auxiliar os clientes em tomadas de decisões de compra informadas. No entanto, a extração e a organização dessas informações a partir de descrições textuais de produtos não estruturadas é uma tarefa desafiadora. Métodos recentes utilizando Grandes Modelos de Linguagem (LLMs) têm demonstrado potencial para superar essas dificuldades, permitindo a extração precisa e estruturada de atributos em formatos como JSON. Para avaliar a qualidade dessas extrações, é crucial que existam *benchmarks* robustos e de qualidade, ao menos tão boas quanto aos resultados das técnicas de *prompt engineering* atualmente utilizadas. Neste trabalho, propomos o JSONLLM, um *benchmark* que agrupa dados de três outros datasets (MAVE, AE110K e OA-Mine) em um novo conjunto de dados anotados com atributos de produtos em formato JSON, cobrindo uma característica não abordada pelos anteriores: valores não textuais. O JSONLLM explora o potencial dos LLMs para identificar e estruturar atributos de produtos em formato JSON. Nosso método utiliza as capacidades de compreensão semântica dos LLMs para reconhecer e categorizar com precisão informações provenientes de descrições diversas. Os objetivos principais deste trabalho incluem: 1. Desenvolver um *benchmark* abrangente e diversificado para a extração de atributos de produtos de *e-commerce*; 2. Expandir o potencial avaliativo sobre os métodos de extração de atributos, não limitante a valores textuais. Através da criação do JSONLLM, pretendemos fornecer uma ferramenta valiosa para a comunidade de pesquisa, facilitando o desenvolvimento e a avaliação de técnicas avançadas de extração de atributos utilizando LLMs.

1 Introdução

A extração e estruturação de atributos de produtos em *e-commerce* representa um desafio crucial devido à diversidade e à complexidade das descrições não estruturadas de produtos. Muitos produtos possuem múltiplos atributos essenciais - como tamanho, cor e material - que são fundamentais para decisões de compra. Métodos tradicionais de extração de informações frequentemente enfrentam limitações em precisão e adaptabilidade a descrições variadas Brinkmann et al. (2024). Recentemente, o uso de Grandes Modelos de Linguagem (LLMs) tem demonstrado potencial significativo para superar esses desafios, permitindo uma extração mais precisa e estruturada em formatos como JSON, facilitando a integração com sistemas de *e-commerce* existentes Sinha and Gujral (2024).

*ORCID: 0000-0002-8156-9551; GitHub: jvfd3; LinkedIn: jvfd3

O desenvolvimento de LLMs requer o processamento de enormes quantidades de dados durante o seu treinamento Brinkmann et al. (2024). Alguns modelos recentes, através de técnicas de *fine tuning* resultaram em melhorias significativas na extração de atributos. E para tal tarefa, é necessário o uso de datasets anotados de alta qualidade para que o modelo aprenda a identificar e estruturar corretamente os atributos dos produtos Yang et al. (2022). No entanto, muitos dos datasets existentes apresentam limitações, como incompletude nas anotações e falta de diversidade nos tipos de atributos representados. Além disso, a maioria dos datasets foca exclusivamente em valores textuais Yang et al. (2022), negligenciando atributos que podem ser numéricos ou categóricos, o que restringe a aplicabilidade dos modelos treinados em dados reais. Em vista disso, os datasets públicos usados como referência, embora comuns na literatura, não representam bem a complexidade e a variação presentes nas descrições reais de produtos. Essa distância cria um problema metodológico: acabamos avaliando modelos avançados com bases que não capturam toda a riqueza e diversidade do domínio, o que pode levar a conclusões imprecisas sobre a verdadeira capacidade desses modelos.

2 Objetivos

Os principais objetivos deste trabalho são: 1. Desenvolver um novo *benchmark* para avaliação de técnicas de extração de atributos de produtos em *e-commerce*; 2. Disponibilizar um *framework* de avaliação para metrificar o desempenho de LLMs na extração de atributos em formato JSON; 3. Apresentar um novo *dataset* anotado com atributos de produtos em formato JSON, abrangendo valores não puramente textuais; 4. Comparar o novo dataset com outros existentes, destacando suas vantagens e limitações.

3 Metodologia

A metodologia envolve a coleta e preparação de conjuntos de dados de descrições de produtos do *e-commerce*, das seguintes bases públicas: **AE-110K** (*Attribute Extraction 110K*), com dimensões (39.489×11) Brinkmann et al. (2024); **?**; **?**; **OA-Mine** (*Open Attribute Mine*), com dimensões (1.938×9) Brinkmann et al. (2024); **?**; **MAVE** (*Multi-source Attribute Value Extraction*), com dimensões $(2.073.115 \times 10)$ Yang et al. (2022).

3.1 Datasets

De cada um destes *datasets* as duplicatas foram removidas, ordenados por descrição e removidas as colunas; Posteriormente, foram repartidos em modelos de treino, validação e teste, na proporção de 80%, 10% e 10%, respectivamente. A Tabela 1 apresenta uma comparação entre os *datasets* utilizados e o JSONLLM, destacando as colunas presentes em cada um deles.

Tabela 1: Comparação entre os atributos presentes nos *datasets*

Coluna	AE110K	MAVE	OA-Mine	JSONLLM
<i>asin</i>			×	×
<i>source</i>		×		×
<i>category</i>		×	×	×
<i>attributes</i>	×	×	×	×
<i>attributes_values</i>	×	×	×	×
<i>json_answer</i>	×	×	×	×
<i>text</i>	×	×	×	×
<i>values</i>	×	×	×	×
<i>values_indices</i>	×	×	×	×
<i>values_text</i>	×	×	×	×
<i>id</i>	×	×		×
<i>candidate_attributes</i>	×			×
<i>candidate_example</i>	×			×
<i>candidate_text</i>	×			×

À seguir descrevemos as colunas da Tabela 1:

- **asin:** identificador único do produto;
- **source:** fonte do dado;
- **category:** categoria do produto;
- **attributes:** lista de atributos do produto;
- **attributes_values:** lista de valores dos atributos do produto;
- **json_answer:** atributos e valores em formato JSON;
- **text:** descrição textual do produto;
- **values:** lista de valores extraídos do texto;
- **values_indices:** índices dos caracteres dos valores extraídos do texto;
- **values_text:** valores extraídos em formato textual;
- **id:** identificador único do exemplo;
- **candidate_attributes:** lista de atributos candidatos para extração;
- **candidate_example:** exemplo de atributo candidato;
- **candidate_text:** texto do exemplo de atributo candidato.

3.2 Modelos

Inicialmente usamos os modelos **LiquidAI/LFM2-350M-Extract** e **LiquidAI/LFM2-1.2B-Extract** para realizar a extração dos atributos. O que resultou em geração de JSON inválido e alucinações recorrentes. Como recursos de correção, foi testado o uso de *role prompting* e *few-shot learning*, mas sem sucesso. Frequentemente o modelo retornava chaves sequenciais (ex: “atributo_1”, “atributo_2”, ...) até que seu limite de tokens fosse atingido. Aumentar a quantidade de tokens apenas aumentou a duração da alucinação, não sendo possível obter saídas válidas. Outro método foi utilizar bibliotecas de *parsing* e correção de JSON, apesar de suceder em alguns casos, a taxa de sucesso era baixa e fugia do escopo esperado do projeto que visa utilizar LLMs para a extração direta de atributos em formato JSON.

Outro modelo utilizado foi o **Gemma-2-2B** da Google com o auxílio da biblioteca **LangExtract**. Aplicamos as técnicas de *role-prompting*, *few-shot learning* e *Chain-of-Thought*, em todas elas com resultados satisfatórios na extração de atributos em formato JSON válido.

3.3 Avaliação

Foram utilizadas seguintes métricas propostas Brinkmann et al. (2024); Sinha and Gujral (2024); Yang et al. (2022) para avaliar a performance dos modelos na extração de atributos em formato JSON:

- **NN:** sem valor predito, sem valor verdadeiro – Verdadeiro Negativo (VN);
- **NV:** com Valor predito, sem valor verdadeiro – Falso Positivo (FP);
- **VN:** sem valor predito, com valor verdadeiro – Falso Negativo (FN);
- **VC:** valor predito corresponde ao valor verdadeiro – Verdadeiro Positivo (VP);
- **VW:** valor predito não corresponde ao valor verdadeiro;

A partir disso, definimos as métricas de precisão (*precision*), revocação (*recall*) e *F1-score*.

3.3.1 Similaridade Semântica

Além das métricas tradicionais de precisão, revocação e *F1-score*, também propomos a utilização de métricas de similaridade semântica para avaliar a qualidade das extrações de atributos em formato JSON. Essas métricas consideram o significado dos valores preditos, permitindo uma avaliação mais robusta em casos onde os valores podem ser expressos de maneiras diferentes, mas possuem o mesmo significado.

Para calcular a similaridade semântica, utilizamos o modelo *encoder-only* **MXBAI (mixedbread-ai/mxbai-embed-large-v1)** para gerar os *embeddings* dos valores preditos e dos valores verdadeiros. Os vetores por token são agregados por *mean pooling*, isto é, pela média dos *embeddings* ao longo da sequência, de modo a capturar predominantemente o conteúdo semântico do texto, independentemente de sua estrutura superficial. Em seguida, calculamos a similaridade do cosseno entre os *embeddings* correspondentes.

4 Liquid Nano Extract

Inicialmente testamos o modelo **liquid-nano-Extract-750M** da *Hugging Face* para a extração de atributos em formato JSON. Porém, não foi possível obter resultados satisfatórios, visto que o modelo não conseguiu gerar saídas válidas em JSON de forma consistente. Além disso, o modelo recorrentemente produzia alucinações sobre os dados gerados, o que comprometeu a confiabilidade das extrações. Devido a essas limitações, optamos por explorar alternativas mais robustas para a tarefa de extração de atributos.

5 Gemma-2-2B com LangExtract

A primeira etapa deste estudo consistiu em avaliar o comportamento do LangExtract no dataset AE110K Brinkmann et al. (2024), um *benchmark* amplamente utilizado para extração de atributos de produtos. O objetivo era verificar se um modelo *open-source* seria capaz de extrair atributos estruturados a partir de textos curtos com qualidade suficiente para gerar catálogos coerentes.

Observou-se que o LangExtract apresentava desempenho superior ao esperado. O modelo identificou atributos explícitos e implícitos sem sinais de alucinação e, em diversos casos, recuperou mais informações úteis do que as anotadas no próprio dataset. Isso evidenciou uma limitação central do AE110K: embora popular, trata-se de um benchmark inconsistente e incompleto, com anotações superficiais e convenções terminológicas heterogêneas. O resultado é que qualquer avaliação baseada em comparação literal entre ground truth e predição penaliza injustamente o modelo, mesmo quando sua saída é mais fiel ao texto que o próprio rótulo de referência.

Diante dessa limitação, tornou-se necessário um método capaz de medir a proximidade conceitual entre predições e rótulos, mesmo quando o dataset oferece apenas uma representação parcial da informação real. Para isso, adotou-se uma métrica de similaridade semântica baseada em embeddings, utilizando o modelo open-source MXBAI (mixedbread-ai/mxbai-embed-large-v1). Ao converter atributos para uma representação textual unificada e comparar os embeddings por similaridade de cosseno, torna-se possível capturar o alinhamento semântico entre as descrições, independentemente de variações lexicais ou estruturais. Nessa métrica, valores próximos de 1 indicam forte convergência conceitual, enquanto valores mais baixos refletem diferenças que, muitas vezes, decorrem de limitações do próprio dataset.

A leitura desses resultados confirma que o LangExtract é altamente competente, enquanto o benchmark é insuficiente para avaliá-lo por métodos tradicionais. A abordagem semântica revelou-se, assim, uma alternativa mais justa e realista, permitindo mensurar a qualidade das extrações de um modelo open-source em cenários onde os datasets públicos são imperfeitos e sub-representam a complexidade real das descrições de produtos.

6 Resultados

Como resultados, apresentamos o *evaluation suite* **JSONLLM** que agrega dados dos datasets AE110K, OA-Mine e MAVE em um novo conjunto de dados anotados com atributos de produtos. Em comparação aos outros datasets, o JSONLLM cobre uma característica não abordada pelos anteriores: valores em formato de lista.

O JSONLLM, com dimensões de (90.000×8) , com descrições textuais únicas de produtos e seus respectivos atributos dispostos em diversos segmentos pré-computados.

7 Conclusão

Este trabalho apresentou o JSONLLM, um novo benchmark para extração de atributos de produtos em e-commerce, unificando e ampliando três datasets amplamente utilizados na área. Ao incluir valores não textuais e fornecer anotações padronizadas em formato JSON, o JSONLLM supre limitações estruturais presentes em bases anteriores e possibilita avaliações mais realistas do desempenho de LLMs. Os experimentos demonstram que abordagens baseadas em modelos abertos, quando combinadas com técnicas adequadas de prompting e avaliação semântica, podem alcançar resultados robustos e consistentes.

Referências

- Brinkmann, A., Shraga, R., and Bizer, C. (2024). Extractgpt: Exploring the potential of large language models for product attribute value extraction. In Delir Haghighi, P., Greguš, M., Kotsis, G., and Khalil, I., editors, *Information Integration and Web Intelligence*, volume 15342, pages 38–52. Springer Nature Switzerland, Cham.
- Sinha, A. and Gujral, E. (2024). Pae: Llm-based product attribute extraction for e-commerce fashion trends. *arXiv preprint arXiv:2405.17533*. Accessed October 2025.
- Yang, Y., Kharitonov, E., Ghosh, S., et al. (2022). Mave: A large-scale dataset for product attribute value extraction. Accessed October 2025.