
Project Proposal

JSONLLM: Extração Escalável de Atributos de Produtos com Grandes Modelos de Linguagem (LLMs)

João Vítor Fernandes Dias *
Computer Science Postgraduate Program
2024711370
Federal University of Minas Gerais
Belo Horizonte, MG; 31270-901
joaovitorfd2000@gmail.com

Melissa Dias Mattos
Computer Science Postgraduate Program
2024675063
Federal University of Minas Gerais
Belo Horizonte, MG; 31270-901
melissadmattos366@gmail.com

†

Abstract

Muitos produtos de *e-commerce* possuem múltiplos atributos – como tamanho, cor e material – que são essenciais para auxiliar os clientes em tomadas de decisões de compra informadas. No entanto, a extração e a organização dessas informações a partir de descrições textuais de produtos não estruturadas é uma tarefa desafiadora. Neste trabalho, propomos o JSONLLM, uma abordagem que explora o potencial dos grandes modelos de linguagem (LLMs) para identificar e estruturar atributos de produtos em formato JSON. Nosso método utiliza as capacidades avançadas de compreensão semântica dos LLMs para reconhecer e categorizar com precisão informações provenientes de descrições diversas e complexas. Os objetivos principais deste projeto incluem: integrar LLMs para a extração de atributos de produtos, garantindo a escalabilidade com sistemas reais de *e-commerce*, padronizando e avaliando a precisão do modelo proposto em comparação a técnicas de *prompt engineering*. Espera-se que o sistema resultante melhore significativamente a precisão da extração de atributos de produtos, facilitando a criação de catálogos de produtos mais ricos e detalhados. Vale ressaltar que a estruturação em JSON facilita a integração com sistemas de *e-commerce* existentes, melhorando a experiência do usuário final.

1 Introdução

A extração e estruturação de atributos de produtos em *e-commerce* representa um desafio crucial devido à diversidade e complexidade das descrições de produtos não estruturadas. Muitos produtos possuem múltiplos atributos essenciais, como tamanho, cor e material, que são fundamentais para decisões informadas de compra. Métodos tradicionais de extração de informações frequentemente enfrentam limitações em precisão e adaptabilidade a descrições variadas Brinkmann et al. (2024). Recentemente, o uso de Grandes Modelos de Linguagem (LLMs) tem demonstrado potencial significativo para superar esses desafios, permitindo uma extração mais precisa e estruturada em formatos como JSON, facilitando a integração com sistemas de *e-commerce* existentes Sinha and Gujral (2024). Esta motivação conduz à proposta do sistema JSONLLM, que visa explorar as capacidades avançadas dos LLMs para melhorar a qualidade da extração e apresentação de atributos de produtos.

* **Contribuição:** idealização do projeto, modularização, pesquisa bibliográfica, testes com Liquid Nano Extract, documentação; **ORCID:** 0000-0002-8156-9551; **GitHub:** jvfd3; **LinkedIn:** jvfd3

† **Contribuição:** testes com LangExtract [<ADICIONAR MAIS DETALHES DA CONTRIBUIÇÃO>]; **ORCID:** 0000-0002-9733-1867; **GitHub:** melissamattos; **LinkedIn:** melissamattos

2 Objetivos

Os principais objetivos deste projeto são: 1. Desenvolver um pipeline que integre LLMs para a extração automática e precisa de atributos de produtos a partir de descrições não estruturadas; 2. Criar um esquema padronizado em formato JSON para representar os atributos extraídos de forma clara e interoperável; 3. Avaliar a precisão e eficiência do modelo proposto em comparação com métodos tradicionais de extração, mediante experimentos controlados; 4. Garantir a escalabilidade e aplicabilidade do sistema em ambientes reais de *e-commerce*, com potencial para integração fácil.

3 Trabalhos Relacionados

4 Metodologia

A metodologia envolve a coleta e preparação de um conjunto de dados representativo de descrições de produtos do *e-commerce*, apoiada por bases públicas como o dataset MAVE (*Multi-source Attribute Value Extraction*), que possui milhões de anotações de pares atributo-valor Yang et al. (2022)³. Após o treino com as bases de dados anotadas o modelo será aplicado no *dataset* da *Track Product Search* da TREC (*Text REtrieval Conference*)⁴ Campos et al. (2023) para avaliação empírica do método de enriquecimento dos dados.

Será adotada uma arquitetura baseada em LLMs, com experimentações utilizando modelos *open-source*, explorando técnicas de *few-shot* e *zero-shot learning* para extração estruturada. Em etapa posterior, através do *finetuning* um modelo pré-treinado será aprimorado através dos exemplos anotados e sua performance será avaliada.

O *pipeline* incluirá a padronização dos atributos extraídos em JSON, com validações automatizadas e refinamento iterativo via técnicas de autoaperfeiçoamento (*self-refinement*) para aumentar a precisão Brinkmann and Bizer (2025). O desempenho do sistema será avaliado por métricas de precisão, *recall* e *f1-score*, comparado a abordagens baseadas em aprendizado de máquina tradicional e ferramentas existentes.

4.1 Datasets

4.2 Modelos

4.3 Avaliação

5 LangExtract

6 Liquid Nano Extract

7 Resultados

Espera-se que o sistema JSONLLM melhore significativamente a precisão da extração de atributos de produtos, permitindo a geração de catálogos detalhados e padronizados. Assim os catálogos poderão ser dispostos em interfaces agradáveis aos usuários para facilitar a avaliação de opções disponíveis.

A contribuição do projeto inclui o desenvolvimento de um *pipeline* LLM para extração de atributos, o avanço no uso de JSON como padrão para dados estruturados em contexto comercial e a validação empírica da superioridade do método em relação a abordagens tradicionais Brinkmann et al. (2024). Além disso, o projeto pode ser aplicado em múltiplos domínios de comércio eletrônico, bem como em outras bases de dados, potencializando a interoperabilidade entre sistemas diversos.

³<https://github.com/google-research-datasets/MAVE>

⁴<https://huggingface.co/datasets/trec-product-search/product-recommendation-2025>

8 Discussão

9 Conclusão

References

- Brinkmann, A. and Bizer, C. (2025). Self-refinement strategies for llm-based product attribute value extraction. *arXiv preprint arXiv:2501.01237*. Accessed October 2025.
- Brinkmann, A., Shraga, R., and Bizer, C. (2024). Extractgpt: Exploring the potential of large language models for product attribute value extraction. In Delir Haghighi, P., Greguš, M., Kotsis, G., and Khalil, I., editors, *Information Integration and Web Intelligence*, volume 15342, pages 38–52. Springer Nature Switzerland, Cham.
- Campos, D., Kallumadi, S., Rosset, C., Zhai, C. X., and Magnani, A. (2023). Overview of the trec 2023 product product search track.
- Sinha, A. and Gujral, E. (2024). Pae: Llm-based product attribute extraction for e-commerce fashion trends. *arXiv preprint arXiv:2405.17533*. Accessed October 2025.
- Yang, Y., Kharitonov, E., Ghosh, S., et al. (2022). Mave: A large-scale dataset for product attribute value extraction. Accessed October 2025.

A Desafios e Estratégias de Mitigação

Entre os principais desafios destacam-se a variabilidade e ambiguidade nas descrições dos produtos que dificultam a extração consistente de atributos; a necessidade de adaptação do modelo a múltiplos domínios de produto; e a escalabilidade do *pipeline* para grandes volumes de dados. Para mitigar esses desafios, serão aplicadas estratégias de refinamento iterativo para corrigir erros, adoção de esquemas JSON flexíveis e extensíveis, e uso de conjuntos de dados amplos e diversificados para o treinamento e validação Brinkmann and Bizer (2025).